Практическая применимость проекта

Сервис может пригодиться садоводам и сотрудникам небольших хозяйств. Пользователь загружает фото листа и получает подсказку, на какую болезнь похожи симптомы. Так будет проще понять, какие растения стоит показать агроному. Это может сэкономить время, когда растений много, а специалиста рядом нет.

Рабочий прототип можно сделать за время проекта. Сложнее добиться того, чтобы он хорошо распознавал болезни на обычных фото: там будут другой свет, фон и сорта растений. Для проверки понадобятся снимки из хозяйств, на которых специалист подтвердил состояние листьев. Отдельно нужно проверить, как модель ведет себя с болезнями, которых не было в обучении. Самая серьезная проблема возникнет, если она назовет больной лист здоровым и человек отложит проверку. Обратная ошибка тоже может навредить: здоровое растение начнут обрабатывать без необходимости. Поэтому ответ сервиса стоит использовать как подсказку, а лечение обсуждать с агрономом.

Заказчик сможет проверить модель на своих фотографиях: сравнить ее ответы с оценкой агронома и посмотреть, какие болезни она чаще путает.

Чекпойнт 2. Анализ изображений

Болезни растений: PlantVillage и PlantDoc

Данные и очистка

Проверили классы, размеры, форматы, яркость и резкость фотографий. В PlantVillage снимки 256×256, в PlantDoc размеры сильно различаются. Для каждого класса сохранили сетку примеров.

Датасет	До очистки	После очистки	Классов
PlantVillage	54 305	54 236	38
PlantDoc	2 572	2 479	28

Код исключил **102 повтора** и **60 фото с конфликтующими метками**. Точные копии определяли по SHA-256, почти-дубликаты по pHash: Хэмминг ≤ 6 и отличие RGB ≤ 0.035. Пороги подобрали по данным PlantVillage, где авторы указали, какие фото показывают один и тот же лист. Исходники сохранены.

Пример почти-дубликата



256×256
Оставили

256×256
Исключили повтор

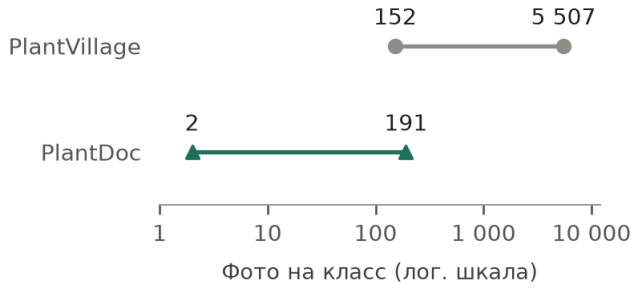
Различается масштаб листа
Хэмминг: 4; RGB: 0.034834

Для сравнения сопоставили названия классов. Из 28 классов PlantDoc не включили 4 с неоднозначными названиями и 1 без тестовых примеров. Получилось **23 общих класса**.

Что показал анализ

Классы несбалансированы. PlantDoc отличается более сложным фоном и более насыщенными цветами. Взяли готовую ResNet18 и построили t-SNE ее признаков: даже при одинаковом составе классов снимки разделяются по датасетам. Поэтому будущую модель отдельно проверим на PlantDoc.

Размеры классов до очистки



Датасеты различаются на t-SNE

По 906 фото; 23 общих класса



Что подготовили для обучения

Сохранили разбиение с **seed=42**: PlantVillage примерно 70/15/15 для train/val/test; PlantDoc по авторским train/test после очистки. Снимки одного листа держим в одной части, чтобы они не попадали одновременно в обучение и проверку. Посмотрели отражения, повороты, изменение цвета и обрезку; для начала выбрали мягкие аугментации.

Расчеты и графики: EDA.ipynb. Исключения: reports/exclusions.csv. Разбиение: splits/manifest.csv.
Источники: PlantVillage и PlantDoc, версии авторов.